

$\|\underline{X}^{\text{cp}}\|_0$  = num of non-zero elements of  $\underline{X}^{\text{cp}}$

3) slice

(c)

$$\|z^c\|_0 = \underline{\underline{z}}$$

$$\int_0^1 = \pi/2e \quad (2)$$

Now  $\int_{0.5}^{\infty} \frac{1}{x^2} dx = \left[ -\frac{1}{x} \right]_{0.5}^{\infty} = 0 - (-2) = 2$

הנ"ל מילויים נספחים בפערת הנקודות שבסעיפים נ"ל, ומיוחדים לנקודות שבסעיפים נ"ל.

100% (כ-1%) של כל גורם נזק מושפע מכך.

לכון על מילוי מילויים (בנין נספחים) ומיון מילויים

• ۱۰۰ نامنها ۲۰۱۷م ۲۰۱۱

• Converging sensor signals (ii)

$$Out = A Im^x$$

٢٠١٢ - نظریہ نوادرانہ

"West" is a "newspaper" in New York.

... 25000 lbs

لے جائیں (iii)

$$\text{close} = (A \oplus B) \ominus B$$

Сергей Смирнов, Илья Кантор, Мария Григорьева, Елена Борисова, Елена Смирнова

•  $\int_{-1}^1 \left( \frac{1}{\sqrt{1-x^2}} + \frac{1}{\sqrt{1-(1-x)^2}} \right) dx$

$$\tilde{w} = \arg \min_w \|w - \tilde{w}\|^2 + \gamma J_{\text{reg}}(w) \quad (\text{IR})$$

2010 7/10, 2011 10 2011 10 2011 10 2011 10 2011 10 2011 10

7 no 1/6 . 28) 15/16 1/10 . 1/10

וְכֵן אָמַר רְבִבָּי רְבִבָּי גַּמְלָא נֶגֶד כְּלֹת.

$$Y^S = X^S \in N^S \quad : \text{לע} \quad (c)$$

לנורווגיה: סטטיסטיקת הנורווגים

: MPD 2020 News

$$\hat{x}_{\text{map}} = \arg \max_{\tilde{x}} P(Y|X) P(x)$$

$\downarrow$

$$(Y - \bar{X}) \sim N(0; I)$$

8/31

$$\hat{X}_{map} = \arg \max \exp \left\{ -\frac{1}{2} (Y-X)^T T^{-1} (Y-X) \right\} \exp \left\{ -\lambda ||X||_0 \right\}$$

$$\tilde{x}_{MAP} = \arg \min \left\{ \frac{1}{2} (Y - X)^T (Y - X) + \lambda \|x^{CS}\|_0 \right\}$$

$$x_{\text{new}} \frac{\partial}{\partial x} \left\{ \quad \right\} = \frac{1}{2} \cdot (-\lambda) (1-x) + \lambda \frac{\partial}{\partial x} \|x^{\text{CS}}\|_e \geq 0$$

$$\tilde{X}_{m_{\text{opt}}} - Y + \lambda \frac{\partial}{\partial x} \|X^S\|_0 \approx 0$$

$$\tilde{X}_{MAD} = Y - \lambda \frac{\partial}{\partial x} \|X^G\|_0$$

$$f(Y; X) = \frac{1}{2} (Y - X)^T (Y - X) = \frac{1}{2} \|Y - X\|_2^2$$

$$g(x) = \lambda ||x^c||_0$$

$$\text{d}m = \int_{\lambda_0}^{\lambda} \mu(\lambda') d\lambda' \quad (3)$$

$$\tilde{\chi}_{max} = Y$$

ככל שמדובר ב"סבירות" מוגדרת נורמלית.

הנורא, וזהו מושגנו, מושגנו יפה, prior

...  $\int \sin x \cos x dx = \frac{1}{2} \sin^2 x + C$

$$X = \pi : Y = Z \quad (5)$$

$$X_{\text{max}} = Y - \frac{\partial}{\partial x} \|x^c\|_0$$

$$\frac{\partial}{\partial x} \|x^S\|_0 \leq 100 \text{ for } x \in \mathbb{R}^{100}$$

לעתה, כזכור, נזכיר את הדרישה שב*א* מושג בב*ב*.

$$\left( \frac{\partial}{\partial x} X \right) > 0 ; \quad X = 0 \Rightarrow \frac{\partial}{\partial x} \|X^C\|_0 = 1$$

$$\left( \frac{\partial}{\partial x} x \right) \geq 0 : x \neq 0 \Rightarrow \frac{\partial}{\partial x} \|x^{\text{es}}\|_0 = 0.$$

$$\left| \frac{d}{dx} f(x) \right| < 0 \quad ; \quad x = 0 \Rightarrow \text{loc max}$$

~~for all  $x \in \mathbb{R}$~~

1-2)  $\lim_{x \rightarrow 0} \frac{\sin x}{x}$  and  $\lim_{x \rightarrow 0} \frac{e^x - 1}{x}$

$$J_{\text{eff}} \cdot 5 \Rightarrow \|Z^{\text{eff}}\|_p \rightarrow \text{JSD} \text{ does not } \stackrel{\text{exist}}{\sim}$$

$$\int_{\gamma} \gamma(s) ds = \int_0^L \frac{2}{\sqrt{2}} \|Z(s)\|_0 ds$$

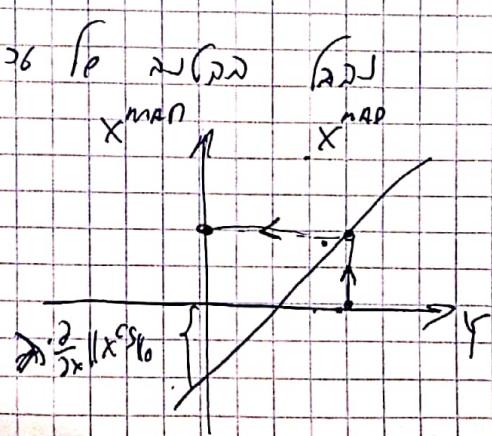
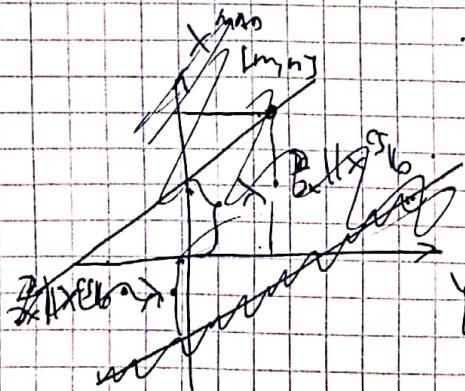
$$X_{moo} = 7 - 7 \cdot 5 = -35$$

• 0  $\pi$   $\cos \theta$   $\int$   $\approx 2$   $\sin \theta$   $\int$

۱۷۸۰ میلادی، نیز اینجا مذکور شد.

Now we have  $\int \frac{dy}{dx} = \int y' dx$  so  $\int y' dx = \int f(x) dx$

• **الخطاب** هو ملخص المحتوى المكتوب في المقالة.



4. a) für

$$Y = H(x+I) \quad : \mu_s (k)$$

: Gero Ls  $\int_{\text{prior}}^{\text{posterior}}$

$$H^{-1}Y = x + I$$

$$\hat{x}_{\text{LP}} = H^{-1}Y - I$$

:  $\hat{x}_{\text{LP}}$  ist die Lösung

$$Y = Hx + H$$

$$Y - H = Hx \quad / \cdot H^T$$

$$H^T(Y - H) = H^T H x \quad / \cdot (H^T H)^{-1}$$

$$(H^T H)^{-1}(H^T Y - H^T H) = x$$

$$(H^T H)^{-1}H^T Y - I = x$$

$$\boxed{\hat{x}_{\text{LP}} = (H^T H)^{-1}H^T Y - I}$$

$$Y = H(x+I) + 2w$$

$$w \sim N(\underline{0}, \sigma_w^2 I) \quad : \text{a priori}$$

: Dazu  $\int_{\text{prior}}^{\text{posterior}}$

$$\frac{1}{2} Y = \frac{1}{2} H(x+I) + w$$

: a priori  $\int_{\text{prior}}^{\text{posterior}}$   $\int_{\text{prior}}^{\text{posterior}}$   $\int_{\text{prior}}^{\text{posterior}}$

$$\textcircled{B} = P_x(\text{oc}) \propto \exp \left\{ - \frac{\|D_s \times x\|_2^2 + \|D_g \times x\|_2^2}{2\sigma_s^2} \right\}$$

: MAP  $\rightarrow$   $\int_{\text{prior}}^{\text{posterior}}$   $\int_{\text{prior}}^{\text{posterior}}$   $\int_{\text{prior}}^{\text{posterior}}$

$$\hat{x}_{\text{MAP}} = \arg \max \underbrace{P_{Y|x,y}}_{\textcircled{A}} \underbrace{P_{x|y}}_{\textcircled{B}}$$

$$\textcircled{A} = P_{Y|x,y} = C \exp \left[ -\frac{1}{2} \underbrace{(x - \mu)^T \Sigma^{-1} (x - \mu)}_{\text{posterior}}$$

$$= C \exp \left[ -\frac{1}{2} \left( \left( \frac{1}{2} Y - \frac{1}{2} H(x+I) - \underline{M}_w \right)^T \left[ \sigma_w^2 I \right]^{-1} \left( \left( \frac{1}{2} Y - \frac{1}{2} H(x+I) - \underline{M}_w \right) \right) \right] =$$

$$= C \exp \left[ -\frac{1}{2} \int \left( \frac{1}{2} (Y - H(x+\epsilon)) - \mu_w \right)^T [\sigma_w^2 \Sigma]^{-1} \left( \frac{1}{2} (Y - H(x+\epsilon)) - \mu_w \right) \right] = \textcircled{A}$$

: 2.35 in UN  $\rightarrow$  0.2  $\rightarrow$  0.82  $\rightarrow$  10  $\rightarrow$  1023

$$P_{Y|X} P_X = C_1 C_2 \left[ -\frac{1}{2} \left[ \left( \frac{1}{2} (Y - H(x+\epsilon)) - \mu_w \right)^T [\sigma_w^2 \Sigma]^{-1} \left( \frac{1}{2} (Y - H(x+\epsilon)) - \mu_w \right) \right] \right]$$

$$\cdot \exp \left[ -\frac{\|\Delta_x x\|_2^2 + \|\Delta_y x\|_2^2}{2\sigma_p^2} \right]$$

$$\hat{x}_{max} = \arg \min \left[ \frac{1}{2} (Y - H(x+\epsilon)) - \mu_w \right]^T [\sigma_w^2 \Sigma]^{-1} \left[ \frac{1}{2} (Y - H(x+\epsilon)) - \mu_w \right] + \frac{\|\Delta_x x\|_2^2 + \|\Delta_y x\|_2^2}{2\sigma_p^2} \right] = \textcircled{C}$$

. 2.35 in UN  $\rightarrow$  0.2  $\rightarrow$  10  $\rightarrow$  1023

$$\hat{x}_{max} = \arg \min [J(x)]$$

(B)  $\rightarrow$  103d / 1023

$$\|\Delta_x x\|_2^2 = (\Delta_x x)^T (\Delta_x x)$$

$$\|\Delta_y x\|_2^2 = (\Delta_y x)^T (\Delta_y x)$$

$$\frac{\partial}{\partial x} \left[ \|\Delta_x x\|_2^2 + \|\Delta_y x\|_2^2 \right] = 2 \Delta_x^T \Delta_x x + 2 \Delta_y^T \Delta_y x$$

$$\frac{\partial}{\partial x} [\textcircled{C}] = -H^T (\sigma_w^2 \Sigma)^{-1} \left( \frac{1}{2} (Y - H(x+\epsilon)) - \mu_w \right) + \lambda \left[ \Delta_x^T \Delta_x + \Delta_y^T \Delta_y \right] x \xrightarrow[\sigma_p^2]{=} 0$$

$$-\frac{(\sigma_w^2 \Sigma)^{-1}}{2} H^T (Y - H(x+\epsilon)) + \sigma_w^2 \Sigma^{-1} H^T \mu_w + \frac{1}{\sigma_p^2} [\Delta_x^T \Delta_x + \Delta_y^T \Delta_y] x = 0$$

$$\cancel{\frac{1}{2} \left[ + \frac{(\sigma_w^2 \Sigma)^{-1}}{2} H^T H + \frac{1}{\sigma_p^2} (\Delta_x^T \Delta_x + \Delta_y^T \Delta_y) \right] x} =$$

$$= (\sigma_w^2 \Sigma)^{-1} H^T \left[ \frac{1}{2} (Y - H) - \mu_w \right]$$

$$\cancel{\frac{1}{2(\sigma_w^2 \Sigma)^2} H^T H + \frac{1}{\sigma_p^2} (\Delta_x^T \Delta_x + \Delta_y^T \Delta_y)} x = \frac{1}{2(\sigma_w^2 \Sigma)^2} H^T (Y - H - 2\mu_w)$$

$$\hat{x}_{max} = \left[ \frac{1}{2(\sigma_w^2 \Sigma)^2} H^T H + \frac{1}{\sigma_p^2} (\Delta_x^T \Delta_x + \Delta_y^T \Delta_y) \right]^{-1} \left[ H^T \left( \frac{1}{2(\sigma_w^2 \Sigma)^2} (Y - H - 2\mu_w) \right) \right] / \cdot 2(\sigma_w^2 \Sigma)^2$$

$$\hat{x}_{max} = \left[ H^T H + 2 \frac{\sigma_w^2}{\sigma_p^2} (\Delta_x^T \Delta_x + \Delta_y^T \Delta_y) \right]^{-1} H^T (Y - H - 2\mu_w)$$

11/12/2023 (c)

לעתה, נוכיח ש  $\hat{x}_n \rightarrow 0$  כ- $n \rightarrow \infty$ :

$$\hat{x}_{n+1} = (M^T H)^{-1} M^T (Y - M - L M_n)$$

לעתה,  $M_n \rightarrow 0$  כ- $n \rightarrow \infty$  ו- $L$  מוגדר כמו:

מקרה מס' 1 (b):

במקרה מס' 1 (b), מוגדר  $L$  כ-\frac{1}{2} \sigma\_n^2 I, כלומר  $L = \frac{1}{2} \sigma_n^2 I$ .

במקרה מס' 2 (b), מוגדר  $L$  כ-\frac{1}{2} \sigma\_n^2 I, כלומר  $L = \frac{1}{2} \sigma_n^2 I$ .

במקרה מס' 3 (b), מוגדר  $L$  כ-\frac{1}{2} \sigma\_n^2 I, כלומר  $L = \frac{1}{2} \sigma_n^2 I$ .

במקרה מס' 4 (b), מוגדר  $L$  כ-\frac{1}{2} \sigma\_n^2 I, כלומר  $L = \frac{1}{2} \sigma_n^2 I$ .

$$Y = Nx ; \quad N \sim (0, \sigma^2 I) \text{ i.i.d} \quad (3)$$

$$0'' \rightarrow -N_i x$$

$$\begin{bmatrix} y \\ \vdots \\ y \end{bmatrix} = \begin{bmatrix} n \\ \vdots \\ n \end{bmatrix} \begin{bmatrix} x \\ \vdots \\ x \end{bmatrix} \quad x \in [Kx_n, 1]$$

$$\text{Var}(Y|X) = \text{Var}(N_{11}x_1 + N_{12}x_2 + \dots + N_{kk}x_k | X)$$

$$\text{Var}(N_i x_i) = \text{Var}(N_{11}x_1) + \text{Var}(N_{12}x_2) + \dots =$$

$$= x_1^2 \underbrace{\text{Var}(N_{11})}_{\sigma^2} + x_2^2 \underbrace{\text{Var}(N_{12})}_{\sigma^2} + \dots =$$

$$= \sigma^2 \cdot \sum x_i^2 = \boxed{\sigma^2 \|x\|^2 = \text{Var}(Y|X)}$$

$$\text{Mean}(Y|X) =$$

$$= \text{mean}(N_{11}x_1) + \text{mean}(N_{12}x_2) + \dots =$$

$$= x_1 \underbrace{\text{mean}(N_{11})}_0 + x_2 \underbrace{\text{mean}(N_{12})}_0 = 0$$

$$\Rightarrow \boxed{Y|X \sim N(0, \sigma^2 \|x\|^2)}$$

*N le ciel et dans la vie, nous sommes tous des personnes qui sont dans le monde, mais nous ne sommes pas tous dans le monde.*

: ML ) good man ( 2 )

$$x_{map} = \underset{x}{\operatorname{argmax}} P(Y|x) \rightarrow \sim N(0, \sigma^2 \|x\|_2^2)$$

$$\begin{aligned} x_{map} &= \underset{x}{\operatorname{argmax}} \exp \left( -\frac{1}{2} (Y - Nx)^T \Lambda^{-1} (Y - Nx) \right) = \\ &= \underset{x}{\operatorname{argmin}} \left\{ \frac{1}{2} (Y - Nx)^T \Lambda^{-1} (Y - Nx) \right\} \approx \\ \frac{\partial}{\partial x} &\rightarrow \frac{1}{2} (-2N^T \Lambda^{-1} (Y - Nx)) = 0 \end{aligned}$$

$$N^T \Lambda^{-1} Y = N^T \Lambda^{-1} Nx$$

$$\begin{aligned} x_{map} &= [N^T \Lambda^{-1} Y]^{-1} [N^T \Lambda^{-1} Y] = \\ &= [N^T \sigma^2 \|x\|_2^2 Y]^{-1} [N^T \sigma^2 \|x\|_2^2 Y] \end{aligned}$$

לפיה,  $x_{map}$  הוא מינימום פונקציית האפסון של פונקציית האפסון. סה"כ,  $\|x\|_2^2$  הוא גודל שפוך ליחסו של גודל  $\sigma^2$ . מכאן ניתן דרשו (הערך המוגן נקבע ב- $\sigma^2$ )

לפיה,  $\|x\|_2^2$  הוא גודל שפוך ליחסו של גודל  $\sigma^2$ . מכאן ניתן דרשו.  $x$  הוא מינימום פונקציית האפסון.